

Multi-Client SSD Scheduling: Mathematical Roadmap (v2)

Working Note

2026 年 4 月 24 日

摘要

本文档整理硕士论文核心数学推导的路线图 (v2)。相对 v1 的主要修订: (1) Block 1 目标从“验证 unimodality”改为“揭示 unimodal 结构”; (2) Step 1.5 补充 unimodality 的物理来源 (E_{hit} 和 p_{hit} 效应平衡); (3) Step 2.4 的 direct term 细化; (4) Step 2.5 新增 binding/non-binding regime 区分; (5) Gate 3 阈值量化; (6) Notation table 补充; (7) 附录新增常见代数错误 checklist。

1 整体框架

数学推导分为四块, 每块结束设一个 gate, gate 不过则 pivot 叙事。

Block	内容	Gate
Block 1	单 client 下 $\tilde{\mu}^{\text{SSD}}(k)$ 的 unimodal 结构刻画	unimodality 是否成立?
Block 2	2-client KKT 分析	externality 项符号与量级?
Block 3	Allocation reversal 区域 $\mathcal{R}$ 刻画	$\mathcal{R}$ 是否足够大?
Block 4	Verifier 约束非 binding 条件 (stretch)	有则加分

Block 1 是地基; Block 2–3 是论文主卖点; Block 4 有就做, 没有不影响整体结构。

2 记号约定

从 Day 1 起固定以下记号, 所有推导均遵从此表。

符号	含义
N	client 总数
i, j'	client index (j' 用于 $j' \neq i$ 的其他 client)
k_i	client i 的 lookahead (verifier 端 speculation 长度)
j	fan-out 的 position index, $j = 0, 1, \dots, k_i$
$F_{i,j}$	client i 在 position j 的 fan-out
$F_{i,0}$	client i 的 base fan-out (Saguaro 命名)
$B_i(\{k_j\})$	client i 的 drafter budget, 作为 $\{k_j\}$ 的隐函数, 非独立决策变量
α_i	client i 的 acceptance rate
r_i	client i 的 power-law cache hit exponent
a_i, b_i	client i 的 drafter timing 系数
$T_V(\cdot)$	verifier wall-time 函数
$T'_V(\cdot)$	verifier wall-time 的 marginal derivative, $T'_V > 0$
C	verifier capacity (token budget per round)
p_{hit}	cache hit rate
$E_{\text{hit}}, E_{\text{miss}}$	cache hit/miss 下的期望 token 产出
k_i^*	单 client 内部最优 lookahead (Block 1 核心量)

Remark 1. *Saguaro* 原文用 K 表示 *speculation lookahead*; 本工作改用 k_i 以和 *client index* 区分。注意 j 是 *fan-out position index*, 不是 *client index*。

Remark 2. B_i 是 $\{k_j\}$ 的隐函数这一事实是本工作相对 *GoodSpeed* (其中 B 不存在) 和 *Saguaro* (其中 B 是固定预算) 的核心建模差异。所有推导必须 *consistent* 地把 B_i 视为 $\{k_j\}$ 的函数而非独立变量。

3 Block 1: 单 client 下 $\tilde{\mu}^{\text{SSD}}(k)$ 的 unimodal 结构

目标. 揭示 $\tilde{\mu}^{\text{SSD}}(k)$ 在 k 方向上的 **unimodal 结构**。这是 *GoodSpeed* 的单调服务曲线和 *Saguaro* 的固定- k 分析都不具备的性质。给出内部最优 k^* 作为 (α, r, a, b, T_V) 的函数, 刻画其 monotonicity 方向。

3.1 Step 1.1: 写 $p_{\text{hit}}(k, B)$

由 *Saguaro Theorem 12*, 在 geometric fan-out $F_j = F_0 \alpha^{j/(1+r)}$ 下:

$$p_{\text{hit}}^p = \alpha^k \cdot p_{\text{hit},p}^{k,\text{all}}(F_k) + \sum_{j=0}^{k-1} \alpha^j (1-\alpha) \cdot p_{\text{hit},p}^j(F_j). \quad (1)$$

代入 power-law $1 - p_{\text{hit},p}^j(F_j) = F_j^{-r}$:

$$p_{\text{hit}}^p = 1 - \alpha^k F_k^{-r} - (1-\alpha) \sum_{j=0}^{k-1} \alpha^j F_j^{-r}. \quad (2)$$

由于 $F_j = F_0 \alpha^{j/(1+r)}$, 有 $F_j^{-r} = F_0^{-r} \alpha^{-jr/(1+r)}$, 所以

$$\alpha^j F_j^{-r} = F_0^{-r} \alpha^{j-jr/(1+r)} = F_0^{-r} \alpha^{j/(1+r)}. \quad (3)$$

记 $\beta := \alpha^{1/(1+r)}$, 则

$$p_{\text{hit}}^p = 1 - F_0^{-r} \left[(1-\alpha)^{-r/(1+r)} \beta^k + (1-\alpha) \cdot \frac{1-\beta^k}{1-\beta} \right]. \quad (4)$$

Remark 3. F_k 项的特殊形式 $F_K = F_0 \alpha^{K/(1+r)} (1-\alpha)^{-1/(1+r)}$ 给出 F_k^{-r} 多一个 $(1-\alpha)^{r/(1+r)}$ 因子。上式中的 $(1-\alpha)^{-r/(1+r)}$ 即由此得来, 推导时务必从 *Saguaro Theorem 12* 重新核对系数。

3.2 Step 1.2: 用 B 消去 F_0

Saguaro 给出 budget 闭式:

$$F_0 = \frac{B}{\beta^k (1-\alpha)^{-1/(1+r)} + (1-\beta^k)/(1-\beta)}. \quad (5)$$

代回 p_{hit}^p 表达式, 得 $p_{\text{hit}}^p(k, B, \alpha, r)$ —— 一个 (k, B, α, r) 的纯函数。

交叉验证. 推完后检查两个极限:

- $\alpha \rightarrow 1$: $p_{\text{hit}} \rightarrow 1$ (每 token 几乎必被接受)
- $B \rightarrow \infty$: $p_{\text{hit}} \rightarrow 1$ (cache 足够大必命中)

3.3 Step 1.3: 写 μ^{SSD} 的完整表达式

$$\mu^{\text{SSD}} = \frac{p_{\text{hit}} \cdot E_{\text{hit}} + (1 - p_{\text{hit}}) \cdot E_{\text{miss}}}{L}. \quad (6)$$

其中:

- $E_{\text{hit}}(k, \alpha)$: cache hit 时期望产出, 近似 $E_{\text{hit}} \approx (1 - \alpha^{k+1})/(1 - \alpha) + O(1)$ 修正项
- $E_{\text{miss}}(k, \alpha) \approx 1$: miss 时只拿到 bonus token
- $L(k, B)$: latency. Setting 3 下 drafter 独立, $T_p < 1$, 所以 $L = 1$ on hit, $L = 1 + T_b$ on miss, T_b 可先取常数

Remark 4. 初次分析建议所有 *timing* 系数取常数。结构清楚后再精细。

3.4 Step 1.4: 代入 $B = B(k)$

$$B(k) = \left\lfloor \frac{T_V - ak}{bk} \right\rfloor_+. \quad (7)$$

Single-client 情形下 T_V 是 k 的函数, 第一次分析可取 T_V 为常数。后续可精细化为 $T_V(k) = T_0 + \tau k$ 。代入后 $\tilde{\mu}^{\text{SSD}}(k) = \tilde{\mu}^{\text{SSD}}(k; \alpha, r, a, b, T_V)$ 是单变量函数。

3.5 Step 1.5: 分析 $\tilde{\mu}^{\text{SSD}}(k)$ 形状

Unimodality 的物理来源 (v2 新增). $\tilde{\mu}^{\text{SSD}}(k)$ unimodal 的根源是两个相反效应的边际平衡:

- **E_{hit} 效应 (偏好大 k):** $E_{\text{hit}}(k) \propto (1 - \alpha^{k+1})/(1 - \alpha)$ 随 k 单调递增。边际效益 $\partial E_{\text{hit}}/\partial k \propto \alpha^k$ 递减但始终为正。物理含义: k 越大, cache hit 时一次推进的 token 越多。
- **p_{hit} 效应 (偏好小 k):** k 增大通过两条路径压低 p_{hit} :
 1. geometric fan-out 摊薄 (固定 B 下, k 长每层 F_j 更小)
 2. drafter 时间限让 $B = (T_V - ak)/(bk)$ 随 k 下降 (分母 bk 增长)

cache miss 的断崖代价 (Saguaro Corollary 16) 让 $\tilde{\mu}^{\text{SSD}}$ 在 p_{hit} 下降时快速下降。

两个效应的边际交汇点就是 k^* 。 E_{hit} 边际递减 + p_{hit} 断崖下降 = unimodal 结构。

k^* 的参数依赖 (v2 新增). 预期 monotonicity 方向:

$$\frac{\partial k^*}{\partial \alpha} > 0, \quad \frac{\partial k^*}{\partial b} < 0, \quad \frac{\partial k^*}{\partial T_V} > 0. \quad (8)$$

直观: α 高的 client 值得更长 lookahead; drafter 慢 (b 大) 的 client 只能选较小 lookahead; verifier 时间多时可以 afford 更长 lookahead。

分析路径 (按推荐顺序). (A3, 先做). 数值验证。用 Python 扫 (α, a, b, T_V) 参数网格, 画 $\tilde{\mu}^{\text{SSD}}(k)$ 的曲线, 肉眼检查 unimodality。1–2 天完成。

(A2, 中等). 证明 unimodality + 给出 k^* 的隐式方程。做渐近分析:

$$\text{大 } T_V \text{ 极限下: } k^* \sim c \cdot \frac{\log T_V}{\log(1/\alpha)}. \quad (9)$$

(A1, 最强). 对 k 求导解闭式 k^* 。 $B(k)$ 含 $1/k$ 项、 p_{hit} 含指数项, 大概率解不出初等闭式; 不要硬推。

Gate 1. Day 4 检查 A3 结果:

- 全部曲线 unimodal $\Rightarrow$ 推进 A2, 是 **论文核心结构性结果**
- 部分 bimodal/monotone $\Rightarrow$ 重新审视参数区间
- 反例条件本身可能是 insight

4 Block 2: 2-client KKT 分析

目标. 写出 Lagrangian, 导 KKT 条件, 识别 externality 项和 two-regime 结构, 对照 GoodSpeed。

4.1 Step 2.1: 优化问题

$$\max_{k_1, k_2 \in \mathbb{Z}_+} \log \tilde{\mu}_1^{\text{SSD}}(k_1, k_2) + \log \tilde{\mu}_2^{\text{SSD}}(k_1, k_2), \quad \text{s.t. } k_1 + k_2 \leq C. \quad (10)$$

其中 $\tilde{\mu}_i^{\text{SSD}}(k_1, k_2) = \mu_i^{\text{SSD}}(k_i, B_i(k_1 + k_2, k_i, a_i, b_i), \alpha_i, r_i)$ 。

4.2 Step 2.2: Lagrangian 和 FOC

放松整数约束:

$$\mathcal{L}(k_1, k_2, \lambda) = \sum_{i=1}^2 \log \tilde{\mu}_i^{\text{SSD}} - \lambda(k_1 + k_2 - C). \quad (11)$$

FOC, 对 k_i 求导 ($i = 1, 2, j' \neq i$):

$$\frac{1}{\tilde{\mu}_i^{\text{SSD}}} \frac{\partial \tilde{\mu}_i^{\text{SSD}}}{\partial k_i} + \frac{1}{\tilde{\mu}_{j'}^{\text{SSD}}} \frac{\partial \tilde{\mu}_{j'}^{\text{SSD}}}{\partial k_i} = \lambda. \quad (12)$$

4.3 Step 2.3: Externality 项

$\tilde{\mu}_{j'}^{\text{SSD}}$ 对 k_i 的依赖只通过 $B_{j'}$ 。因为

$$B_{j'} = \frac{T_V(k_1 + k_2) - a_{j'} k_{j'}}{b_{j'} k_{j'}}, \quad (13)$$

有

$$\frac{\partial \tilde{\mu}_{j'}^{\text{SSD}}}{\partial k_i} = \frac{\partial \mu_{j'}^{\text{SSD}}}{\partial B_{j'}} \cdot \frac{\partial B_{j'}}{\partial k_i} = \frac{\partial \mu_{j'}^{\text{SSD}}}{\partial B_{j'}} \cdot \frac{T'_V(k_1 + k_2)}{b_{j'} k_{j'}}. \quad (14)$$

关键观察. $\partial\mu_{j'}^{\text{SSD}}/\partial B_{j'} > 0$ (Saguaro: 更大 B 更高 p_{hit}), $T'_V > 0$ (load 增 $\Rightarrow$ verifier 变慢), $b_{j'}k_{j'} > 0$. 所以

$$\boxed{\frac{\partial\tilde{\mu}_{j'}^{\text{SSD}}}{\partial k_i} > 0.} \quad (15)$$

这就是 **positive externality**: client i 增大 k_i 拉长 T_V , 反而让 client j' 的 $B_{j'}$ 变大, 其 $p_{\text{hit}j'}$ 提升。

4.4 Step 2.4: Own effect (v2 细化)

$\tilde{\mu}_i^{\text{SSD}}$ 对 k_i 依赖走两条路径:

$$\frac{\partial\tilde{\mu}_i^{\text{SSD}}}{\partial k_i} = \underbrace{\frac{\partial\mu_i^{\text{SSD}}}{\partial k_i}\bigg|_{B_i}}_{\text{direct}} + \underbrace{\frac{\partial\mu_i^{\text{SSD}}}{\partial B_i} \cdot \frac{\partial B_i}{\partial k_i}}_{\text{indirect}}. \quad (16)$$

Direct term 细化 (v2 新增). Direct term 本身可进一步拆为两个子项:

$$\frac{\partial\mu_i^{\text{SSD}}}{\partial k_i}\bigg|_{B_i} = \underbrace{p_{\text{hit}} \cdot \frac{\partial E_{\text{hit}}}{\partial k_i}}_{\text{正: } E_{\text{hit}} \text{ 增长}} + \underbrace{(E_{\text{hit}} - E_{\text{miss}}) \cdot \frac{\partial p_{\text{hit}}}{\partial k_i}\bigg|_{B_i}}_{\text{符号取决于 } k}. \quad (17)$$

- $p_{\text{hit}} \cdot \partial E_{\text{hit}}/\partial k_i > 0$: cache hit 时每次能推进更多 token
- $(E_{\text{hit}} - E_{\text{miss}}) \cdot \partial p_{\text{hit}}/\partial k_i|_{B_i}$: $(E_{\text{hit}} - E_{\text{miss}}) > 0$; 当固定 B_i 下 p_{hit} 随 k_i 递减 (fan-out 摊薄) 时, 此项为负

关键联动 (v2 新增): Direct term 在 $k_i < k_i^*$ 时为正, $k_i > k_i^*$ 时为负——这正是 Block 1 建立的 unimodality 的 FOC 反映。Direct term 在 $k_i = k_i^*$ 处为零。

Indirect term. 注意 T_V 也依赖 k_i :

$$\frac{\partial B_i}{\partial k_i} = \frac{\partial}{\partial k_i} \left[\frac{T_V(k_1 + k_2) - a_i k_i}{b_i k_i} \right] = \frac{T'_V \cdot k_i - T_V}{b_i k_i^2}. \quad (18)$$

(化简后, 推导时验算。)

- $T'_V k_i < T_V$ 时 (常见): $\partial B_i/\partial k_i < 0$. k_i 增 $\Rightarrow B_i$ 减
- $T'_V k_i > T_V$ 时 (强凸 T_V , 罕见): $\partial B_i/\partial k_i > 0$

综合 direct + indirect, own effect $\partial\tilde{\mu}_i^{\text{SSD}}/\partial k_i$ 在 k_i^* 两侧分别为正/负, 延续 Block 1 的 unimodal 结构。

4.5 Step 2.5: 两种 regime 与 GoodSpeed 对照 (v2 重写)

GoodSpeed 的 FOC. log-utility 形式:

$$\frac{\mu'_i(k_i)}{\mu_i(k_i)} = \lambda_{\text{GS}}, \quad \mu_i(k_i) = \frac{1 - \alpha_i^{k_i+1}}{1 - \alpha_i}. \quad (19)$$

由于 $\mu_i(k_i)$ 严格递增 $\Rightarrow \mu'_i(k_i) > 0$ 处处成立 $\Rightarrow$ GoodSpeed 最优解总在 $\lambda_{\text{GS}} > 0$, **verifier 约束 always binding**。

本工作 FOC 的两种 regime (v2 新增). 由 (12), 有:

$$\underbrace{U'(\tilde{\mu}_i^{\text{SSD}}) \frac{\partial \tilde{\mu}_i^{\text{SSD}}}{\partial k_i}}_{\text{own (可正可负)}} = \lambda - \underbrace{U'(\tilde{\mu}_{j'}^{\text{SSD}}) \frac{\partial \tilde{\mu}_{j'}^{\text{SSD}}}{\partial k_i}}_{\text{externality (正)}}. \quad (20)$$

两种可能的平衡态:

- **Binding regime** ($\lambda > 0$): 最优 k_i 处 own 边际为正 ($k_i < k_i^*$), verifier 约束紧。扩大 k_i 仍然对 i 自己有益, 只是被 verifier 预算限制。这类似 GoodSpeed 的情形。
- **Non-binding regime** ($\lambda = 0$): 最优 k_i 处 own 边际为负 ($k_i > k_i^*$), 意味着 **系统在给 i 分配“超出其自身最优”的 k_i , 只为了通过 externality 帮助别人**。此时 verifier 约束未满足。GoodSpeed 不具备这种 regime, 因其 μ_i 单调。

与 GoodSpeed 的 FOC 差异总结.

组成	GoodSpeed	本工作
Own direct (E_{hit} 增长)	✓ 总正	✓ k_i^* 两侧异号
Own direct (p_{hit} 下降)	× 模型无	✓ fan-out 摊薄效应
Own indirect (B_i via k_i)	× 模型无 B	✓ 通常为负
Externality (other B_j)	× 无耦合	✓ 严格正
可行域边界 binding?	总 binding	可能 non-binding

本工作多出的三项 (own direct p_{hit} 、own indirect、externality) 就是 allocation reversal 的代数起源。

5 Block 3: Reversal region $\mathcal{R}$

目标. 定义参数区域 $\mathcal{R} \subset \{(\alpha_1, \alpha_2, r_1, r_2, a_1, a_2, b_1, b_2)\}$, 在其中

$$\text{sign}(k_1^{\text{GS}} - k_2^{\text{GS}}) \neq \text{sign}(k_1^* - k_2^*). \quad (21)$$

5.1 Step 3.1: 求 GoodSpeed 最优 ($k_1^{\text{GS}}, k_2^{\text{GS}}$)

GoodSpeed FOC 在 $U = \log$ 下有 proportional fairness 解。数值梯度求解即可; 或从 $k_i^{\text{GS}} \propto \log(1/\alpha_i)$ 的启发式出发。

5.2 Step 3.2: 求本工作最优 (k_1^*, k_2^*)

放松整数约束, 用 `scipy.optimize` 在 (k_1, k_2) grid 上找 $\arg \max$, 再 fine-tune。

5.3 Step 3.3: 扫参数空间

- 固定 r, a 相同, 扫 $(\alpha_1, \alpha_2) \in [0.5, 0.95]^2$, 画 reversal map
- 改变 (b_1, b_2) 的异质性, 看 reversal 区域移动方向
- 多参数扫描产生 2D 热力图序列 (8–12 张)

5.4 Step 3.4: 从数值现象猜测 $\mathcal{R}$ 解析形式

理想情况下可猜出判据, 形如:

$$\mathcal{R} = \left\{ (\alpha_1, \alpha_2, b_1, b_2) : \alpha_1 > \alpha_2 \text{ 但 } \frac{b_1}{\alpha_1^c} > \frac{b_2}{\alpha_2^c} \right\}, \quad (22)$$

即某种 effective acceptance rate 判据。这类形式是论文 signature theorem。

若猜不出干净形式, 退一步给出 $\mathcal{R}$ 的边界方程 (由 $k_1^* = k_2^*$ 曲线刻画), 即使不能解析化简也可作为数值描述。

Gate 3 (v2 量化). 可量化判据:

- $\mathcal{R}$ 在真实参数空间 (Saguaro-calibrated 分布) 占比 $\geq 20\%$
- 在 $\mathcal{R}$ 内, GoodSpeed vs 本工作的 utility gap 平均 $\geq 15\%$
- 两条件同时满足 $\Rightarrow$ signature result 站得住

不满足 $\Rightarrow$ pivot 到 “GoodSpeed 的 geometric fan-out 在 multi-client 下 near-optimal” 的 negative result。

6 Block 4: Verifier 约束非 binding (Stretch)

目标. 给出最优 (k_1^*, k_2^*) 使 $k_1^* + k_2^* < C$ 的参数条件。

这对应 (12) 中 $\lambda = 0$ 的情况, 即:

$$\frac{1}{\tilde{\mu}_i^{\text{SSD}}} \frac{\partial \tilde{\mu}_i^{\text{SSD}}}{\partial k_i} + \frac{1}{\tilde{\mu}_{j'}^{\text{SSD}}} \frac{\partial \tilde{\mu}_{j'}^{\text{SSD}}}{\partial k_i} = 0, \quad i = 1, 2. \quad (23)$$

即 own effect (在 $k_i > k_i^*$ 时为负) 与 externality (总正) 正好抵消。

直觉. b_i 足够大 (drafter 昂贵) 时, k_i^* 本身被压小, 过多的 k_i 让 own 负项主导, scheduler 不愿再加 k_i 。显式阈值:

$$b^*(\alpha, r, T_V, \dots) : \quad b_i > b^* \Rightarrow \text{非 binding}. \quad (24)$$

7 工程建议

记号一致性. 第 2 节的 notation table 放在所有推导笔记首页, 每次推导前对一次。

计算工具.

- Python + SymPy: 符号推导 (尤其 Block 1 的代数化简)
- Python + NumPy/SciPy: 数值扫描 (Block 1 Step 1.5, Block 3)
- Matplotlib: 画图
- 不建议 Mathematica, 除非已熟悉

推导顺序. 所有结构性结论 **先在 2-client 建立**, 写 paper 时也以 “2-client analysis” 为 main result, “extension to N clients” 作为推广章节。不要反过来做 general N 。

8 第一周任务表

Day	任务
1	定记号表, 重读 Saguaro Theorem 12 和 Section 4.1, 手抄推导
2	Block 1 Step 1.1–1.3: 写出 $\mu^{\text{SSD}}(k, B, \alpha, r)$ 闭式
3	Block 1 Step 1.4–1.5: 代入 $B(k)$, Python 画 $\tilde{\mu}^{\text{SSD}}(k)$ 曲线
4	Gate 1: 检查 unimodality. 不过则 pivot.
5–7	Block 2 Step 2.1–2.5: 2-client FOC 推导

Day 4 的 decision point. 若 $\tilde{\mu}^{\text{SSD}}(k)$ 不 unimodal, 整个 v4.1 需回炉。必须尽早 check。

附录 A: 和合作者 cross-check 建议

Saguaro Theorem 12 的代数琐碎但易错。建议:

- Day 2–3 独立推出 $\mu^{\text{SSD}}(k, B, \alpha, r)$
- 把推导过程 (中间步骤都写) 给第二人 cross-check
- 特别核对 F_K 的 $(1 - \alpha)^{-1/(1+r)}$ 因子, 这是最容易算错的地方
- 确认 $E_{\text{hit}}, E_{\text{miss}}, L$ 的具体取值约定 (Saguaro Theorem 7)

附录 B: 常见代数错误 checklist (v2 新增)

以下是推导中最容易出错的点, 推完每个 step 后对一次。

符号类.

- F_K 的 $(1 - \alpha)^{-1/(1+r)}$ 系数方向是 **负指数** (不是正)
- $\beta = \alpha^{1/(1+r)}$ (不是 α^{1+r})
- $\partial B / \partial k$ 的符号取决于 $T'_V k$ vs T_V 的大小, 常见情况下为负
- T'_V 的符号始终为正 (verifier 越 load 越慢)

定义类.

- E_{hit} 是否包括 bonus token? (Saguaro 约定: 包括)
- E_{miss} 在 Setting 3 下约定为 ≈ 1 (只剩 backup bonus)
- k_i^* 是固定 $\{k_j\}_{j \neq i}$ 的最优, 不是全局最优
- B_i 是 $\{k_j\}$ 的隐函数, 不是独立变量

极限验证.

- $\alpha \rightarrow 1$: $p_{\text{hit}} \rightarrow 1$, $E_{\text{hit}} \rightarrow \infty$ (需要 care)
- $\alpha \rightarrow 0$: p_{hit} 行为应合理 (draft 基本无用, miss 为主)

- $B \rightarrow \infty$: $p_{\text{hit}} \rightarrow 1$ (cache 大必命中)
- $B \rightarrow 0$: $p_{\text{hit}} \rightarrow 0$ (除非 $k = 0$)
- $T_V \rightarrow \infty$: $B \rightarrow \infty$ (k^* 大幅增加)
- $b \rightarrow \infty$: $B \rightarrow 0$ (drafter 太慢准备不了)

一致性.

- Direct term 在 $k_i = k_i^*$ 处应为零 (Block 1 unimodal 的 FOC 反映)
- Own + externality + λ 的符号对称性 (对 k_1, k_2 的 FOC)
- 两种 regime (binding/non-binding) 互斥且覆盖所有 KKT 解